ZALLOT Tristan : FISA4
Planchon Doryan : FISA4
Steed Junior Allan : FISA4
2éme année de Cycle Ingénieur
ISEN Brest – Année 2025 - 2026

Projet Trinome 4 G2

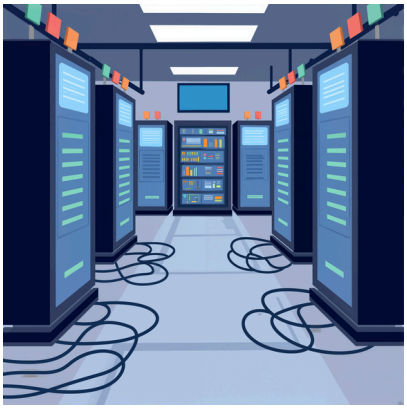

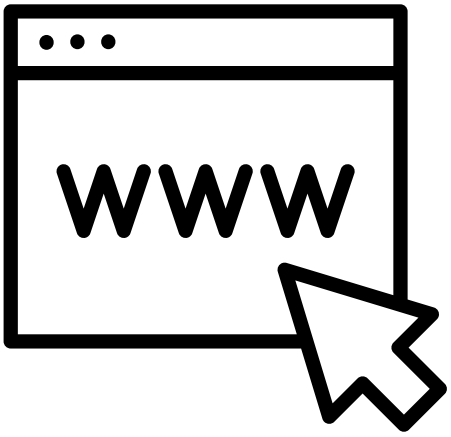

Lien GitHub

A - Besoin Client 1

1- Introduction

L’objectif de ce projet était de regrouper des arbres urbains selon leur taille, à partir d’un jeu de données réel. Pour cela, j’ai utilisé des algorithmes d’apprentissage non supervisé.
Le travail s’est déroulé en trois grandes étapes : la préparation des données, le choix et la comparaison des algorithmes de clustering, et enfin la mise en place d’un outil de prédiction.

2- Préparation des données

Sélection des variables

La première étape a consisté à identifier les variables pertinentes pour le clustering. Après analyse du jeu de données, j’ai retenu deux variables : la hauteur totale de l’arbre en mètres et le diamètre du tronc en centimètres. Ce choix se justifie par le fait que ces deux mesures représentent directement la taille d’un arbre.

Normalisation

Avant d’appliquer les algorithmes, j’ai normalisé les deux variables avec un StandardScaler. Cette étape est indispensable car la hauteur et le diamètre n’ont pas la même échelle : sans normalisation, le diamètre aurait dominé le calcul des distances et biaisé les résultats. En centrant et réduisant les deux variables, chacune contribue équitablement au regroupement.
Le scaler a été sauvegardé après l’entraînement pour permettre d'exécuter le script de fin sans devoir tout recalculer.

2- Clustering

Choix du nombre de clusters

Avant de comparer les algorithmes, il a fallu déterminer combien de clusters utiliser. Deux configurations ont été testées : k = 2, qui sépare les arbres en Petit et Grand, tandis que k = 3 en Petit, Moyen et Grand . Pour un choix entre ces deux clusters, trois métriques d'évaluation ont été calculées.

Choisir une seule métrique n'aurait n'était pas suffisante, il est plus préférable d'avoir plusieurs propositions, pour ce faire j'ai utilisé : "Silhouette", "Davies-Bouldin", "Calinski-Harabasz". Pour choisir quel est le meilleur cluster, j'ai mis en place un système de vote : le k qui remporte le plus de métriques est retenu.

Comparaison des algorithmes

Une fois le nombre de clusters déterminé, j'ai comparé deux algorithmes de clustering différents afin de sélectionner le plus adapté au problème.
Le premier est KMeans, l'algorithme le plus classique : il cherche à minimiser la distance entre chaque point et le centre de son cluster. Le deuxième est AgglomerativeClustering, qui adopte une approche différente : il part de chaque arbre comme un groupe à part entière, puis fusionne progressivement les plus proches jusqu'à atteindre le nombre de clusters souhaité.
Ces deux algorithmes ont été entraînés pour k = 2 et k = 3, et évalués avec les mêmes trois métriques. Pour chaque valeur de k, l'algorithme qui obtient les meilleurs résultats sur au moins deux métriques sur trois est retenu automatiquement.
Pour k=2

Algorithme/Métrique	silhouette	davies_bouldin	calinski_harabasz
KMeans	0.4882	0.7842	11514.2163
AgglomerativeClustering	0.4285	0.8483	9518.7964

Pour k=3

Algorithme/Métrique	silhouette	davies_bouldin	calinski_harabasz
KMeans	0.3946	0.8735	10650.6743
AgglomerativeClustering	0.3922	0.9224	8438.3544

On se retrouve donc avec le meilleur algorithme de clustering pour chaque k.

Attribution des catégories

Une fois les clusters formés, il faut leur donner un sens. Pour cela, j'ai calculé la hauteur moyenne de chaque cluster et ordonné les groupes du plus petit au plus grand. Le cluster avec la hauteur moyenne la plus faible est nommé « Petit », le plus élevé est nommé « Grand », et l'intermédiaire « Moyen » pour k = 3.

4- Sauvegarde des modèles

Pour pouvoir réutiliser les résultats du clustering sans relancer l'entraînement à chaque fois, j'ai sauvegardé deux types de fichiers.
Les fichiers .pkl contiennent les objets Python : le scaler et les deux modèles de clustering (un pour k = 2, un pour k = 3). Les fichiers .json contiennent les métadonnées associées : le nom de l'algorithme retenu, la correspondance entre numéro de cluster et catégorie, et les variables utilisées.

5- Visualisation sur carte interactive

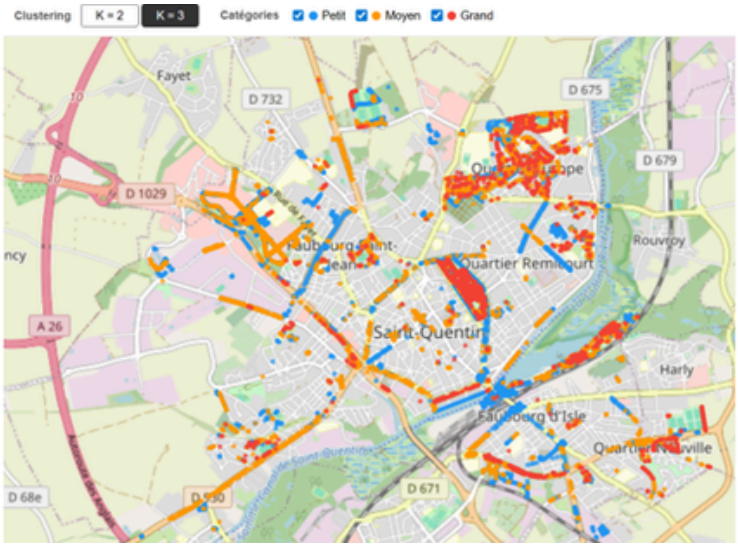

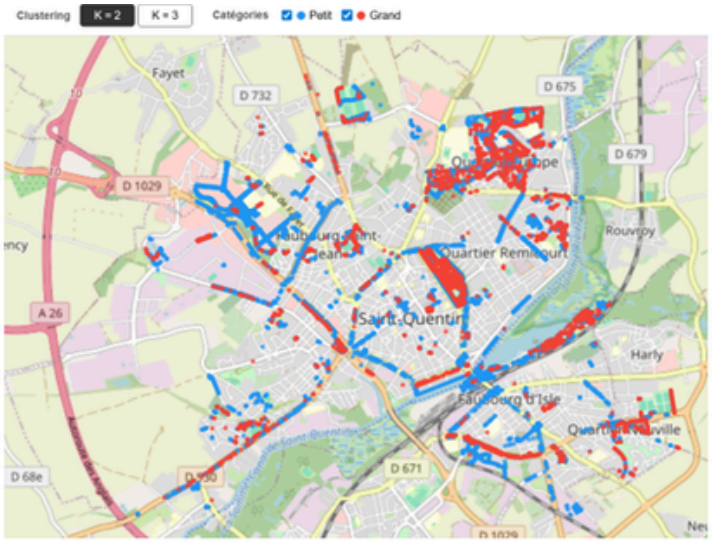

La carte a été conçue pour être interactive et permettre à l'utilisateur d'explorer les données à sa guise. Deux contrôles ont été intégrés dans une barre en haut de l'interface.
Le premier est un bouton permettant de basculer entre le clustering à k = 2 et le clustering à k = 3. Cela permet de comparer visuellement les deux segmentations sur la même carte.
Le second contrôle est un système de cases à cocher permettant de filtrer les catégories affichées. L'utilisateur peut par exemple choisir de n'afficher que les grands arbres, ou comparer Petit et Grand en masquant Moyen.

6- Script de prédiction

Principe

L'objectif du script est de permettre à n'importe qui de prédire la catégorie d'un arbre à partir de sa hauteur et du diamètre de son tronc. Le script charge les fichiers sauvegardés une seule fois au démarrage, applique la même normalisation que lors de l'entraînement, puis utilise le modèle pour prédire.

Interface utilisateur

Le script propose une interface en ligne de commande simple et interactive. L'utilisateur est invité à saisir successivement la hauteur de l'arbre, le diamètre du tronc, et le nombre de clusters souhaité (2 ou 3). Le script affiche ensuite la catégorie prédite.

B - Besoin Client 2

1- Introduction

L'objectif de cette partie est de développer un modèle capable de prédire l'âge des arbres à partir de leurs caractéristiques. Cette approche permet d'automatiser une estimation qui peut être difficile à obtenir directement sur le terrain. Elle s'inscrit dans une logique d'apprentissage supervisé, où le modèle apprend à partir de données existantes pour généraliser à de nouvelles observations.

2- Préparation des données

2-1 Chargement des données

Les données issues de la phase Big Data sont utilisées comme base de travail. Cette étape est nécessaire pour s'assurer que les données sont correctement importées et exploitables.
Une mauvaise importation ou des données mal structurées peuvent fausser toute l'analyse. Il est donc essentiel de vérifier la qualité des données dès le départ.

2-2 Sélection des variables

Une sélection des variables pertinentes a été réalisée afin de construire un modèle capable de prédire l'âge des arbres. Les variables retenues apportent des informations complémentaires sur les caractéristiques physiques et le contexte des arbres.

Les variables de type dimensionnel comme haut_tot, haut_tronc et tronc_diam sont particulièrement importantes. En effet, la croissance d'un arbre est directement liée à son âge : un arbre plus âgé aura généralement un diamètre de tronc plus important et une hauteur plus élevée. Ces variables sont donc fortement corrélées à la cible.

La variable clc_nbr_diag (nombre de diagnostics) peut également être pertinente car elle peut refléter un suivi plus fréquent des arbres plus anciens ou présentant des caractéristiques particulières.

Les variables contextuelles telles que clc_quartier, fk_situation ou fk_arb_etat permettent d'intégrer l'environnement de l'arbre. Par exemple, certains quartiers peuvent contenir des arbres plus anciens que d'autres, et l'état de l'arbre peut être lié à son âge.

Les variables liées à la nature de l'arbre, comme feuillage, nomfrancais ou remarquable, apportent des informations sur l'espèce ou les caractéristiques spécifiques. Certaines espèces ont une croissance plus rapide que d'autres, ce qui influence directement leur âge pour une taille donnée.

Enfin, les variables jugées non pertinentes (comme les identifiants ou les informations techniques sans lien direct avec la croissance) ont été exclues afin de réduire le bruit dans les données et améliorer les performances du modèle.
Cette sélection permet ainsi de combiner des informations physiques, environnementales et biologiques afin de fournir au modèle une vision complète des facteurs influençant l'âge des arbres.

2-3 Traitement des valeurs manquantes - Imputation

Les valeurs manquantes présentes dans le jeu de données sont traitées à l'aide d'une technique appelée imputation. L'imputation consiste à remplacer les valeurs absentes par des valeurs estimées, par exemple la moyenne ou la médiane pour les variables numériques, ou la valeur la plus fréquente pour les variables catégorielles.

Cette étape contribue à améliorer la qualité du jeu de données et la stabilité du modèle.

2-4 Encodage des variables catégorielles

Les variables qualitatives sont transformées en variables numériques.

Les modèles d'apprentissage automatique ne peuvent pas traiter directement des données textuelles. L'encodage permet de rendre ces informations exploitables.

2-5 Normalisation des données

Les variables numériques sont normalisées à l'aide de la fonction StandardScaler() du module scikit-learn. Cette fonction permet de centrer les données (moyenne égale à 0) et de les réduire (écart-type égal à 1).

3- Nouvelles variables

De nouvelles variables sont créées à partir des variables existantes, notamment sous forme de ratios.

Les variables dérivées permettent souvent de mieux représenter les relations entre les données. Elles peuvent améliorer significativement les performances du modèle en apportant une information plus pertinente.

4- Transformation de la variable cible

La variable cible age_estim, initialement continue, est transformée en une variable catégorielle afin de formuler le problème sous forme de classification. Cette transformation consiste à regrouper les valeurs d'âge en plusieurs classes distinctes, par exemple :

- arbres jeunes : âge inférieur à un certain seuil,
- arbres intermédiaires : âge compris entre deux seuils,
- arbres âgés : âge supérieur à un seuil élevé.

Cette discrétisation permet de simplifier le problème en réduisant la précision de la prédiction, tout en conservant une information pertinente sur la catégorie d'âge de l'arbre.

```
classe_age
Moyen    5375
Jeune    3532
Vieux     644
Name: count, dtype: int64
```

5- Séparation des données

Les données sont divisées en un jeu d'entraînement et un jeu de test.

Cela permet d'évaluer le modèle sur des données qu'il n'a jamais vues. Sans cette séparation, il serait impossible de mesurer correctement la capacité du modèle à généraliser.

6- Modélisation

6-1 Choix des modèles

Plusieurs modèles d'apprentissage supervisé ont été testés afin de déterminer celui qui est le plus adapté à la prédiction des classes d'âge des arbres. Parmi eux, on retrouve notamment la régression logistique, le Random Forest et le Gradient Boosting.

Chaque modèle repose sur des principes différents et possède ses propres avantages. La régression logistique est un modèle simple et rapide, qui permet d'obtenir une première base de comparaison. Le Random Forest, basé sur un ensemble d'arbres de décision, est capable de capturer des relations complexes entre les variables et offre généralement de bonnes performances sur des données tabulaires. Le Gradient Boosting, quant à lui, construit les modèles de manière itérative et peut fournir des résultats très précis, au prix d'un temps de calcul plus important.
Le fait de tester plusieurs modèles permet de comparer leurs performances à l'aide des mêmes données et des mêmes métriques. Cela permet de sélectionner le modèle le plus performant et le plus adapté au problème étudié.
Enfin, cette approche permet également de vérifier que les résultats ne dépendent pas d'un seul modèle, mais sont cohérents quelle que soit la méthode utilisée.

	model	cv_accuracy_mean	cv_accuracy_std
1	RandomForest	0.962435	0.006353
2	GradientBoosting	0.944241	0.004485
0	LogisticRegression	0.939267	0.003108

6-2 Validation croisée

Afin d'évaluer de manière fiable les performances des modèles, une validation croisée stratifiée a été mise en place. Cette méthode consiste à diviser le jeu de données en plusieurs sous-ensembles (ou folds) et à entraîner le modèle sur une partie des données tout en le testant sur une autre, et ce de manière répétée.
L'utilisation d'une validation croisée permet de réduire la dépendance aux choix du découpage des données (train/test) et d'obtenir une estimation plus robuste des performances du modèle. La stratification garantit que la répartition des classes d'âge est conservée dans chaque sous-ensemble, ce qui est particulièrement important en cas de déséquilibre des classes.
Cette étape permet donc de s'assurer que les résultats obtenus sont généralisables et non liés à un cas particulier.

6-3 Optimisation des hyperparamètres (GridSearchCV)

Afin d'améliorer les performances du modèle, une optimisation des hyperparamètres a été réalisée à l'aide de la méthode GridSearchCV. Cette technique consiste à tester automatiquement plusieurs combinaisons de paramètres afin d'identifier la configuration la plus performante.
Dans le cas du Random Forest, plusieurs paramètres ont été explorés, tels que le nombre d'arbres, la profondeur maximale ou encore les critères de division. Chaque combinaison est évaluée à l'aide de la validation croisée, ce qui permet de sélectionner les paramètres offrant le meilleur compromis entre performance et généralisation.
Cette approche systématique permet d'optimiser le modèle de manière rigoureuse et d'éviter des choix arbitraires de paramètres.

7- Évaluation des performances

7-1 Métriques

Les performances du modèle sont évaluées à l'aide de plusieurs métriques adaptées à la classification :

- Accuracy : proportion de prédictions correctes sur l'ensemble des observations.
- Précision : proportion de prédictions correctes parmi les prédictions positives.
- Recall : capacité du modèle à identifier correctement les observations appartenant à une classe donnée.
- F1-score : moyenne harmonique entre la précision et le recall, permettant d'obtenir une mesure équilibrée.

L'utilisation de plusieurs métriques permet d'obtenir une évaluation plus complète du modèle, notamment en cas de déséquilibre des classes.

7-2 Matrice de confusion

La matrice de confusion permet d'analyser en détail les performances du modèle en comparant les classes réelles aux classes prédites. Elle met en évidence les erreurs de classification et permet d'identifier les confusions entre les différentes classes.

Les résultats montrent que la majorité des prédictions se situent sur la diagonale de la matrice, ce qui indique une bonne performance globale. Les erreurs observées concernent principalement des confusions entre classes proches, notamment entre les arbres jeunes et moyens, ou entre moyens et vieux.

Aucune confusion significative n'est observée entre les classes extrêmes (jeune et vieux), ce qui confirme la cohérence du modèle.

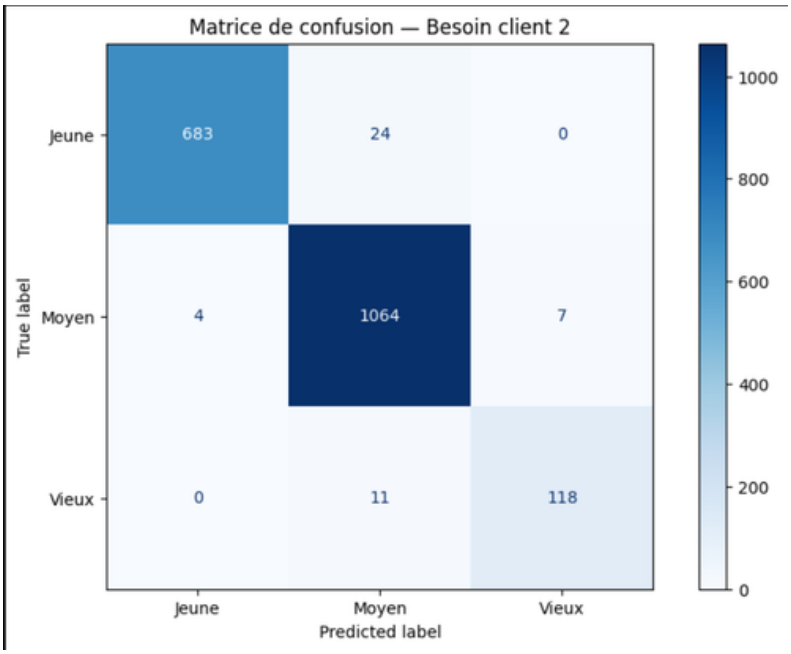

Rapport - Besoin Client 3

Système d'alerte pour les tempêtes - Prédiction des arbres à risque

---

1. Introduction et contexte

1.1 Rappel du besoin client

La ville de Saint-Quentin (Aisne) souhaite mettre en place un **système d'alerte** pour prédire les arbres susceptibles d'être déracinés en cas de tempête. L'objectif est de pouvoir prioriser les inspections et les interventions préventives avant chaque épisode venteux.

1.2 Périmètre de l'étude

L'étude porte sur le patrimoine arboré de la ville, soit **9 551 arbres** répertoriés dans la base de données nettoyée issue de la partie Big Data.

1.3 Démarche méthodologique

Notre approche s'articule autour de quatre phases :

Phase	Objectif	Livrable
1. Diagnostic	Analyser la faisabilité et les contraintes	État des lieux des données
2. Construction	Définir des règles de détection	Score de risque métier
3. Évaluation	Valider sur données historiques	Analyse des performances
4. Recommandation	Proposer un outil opérationnel	Guide d'utilisation

2. Diagnostic des données

2.1 Analyse de la variable cible

La variable `fk_arb_etat` (état de l'arbre) a été analysée comme suit :

État	Effectif	Pourcentage
EN PLACE	8 694	91.0%
SUPPRIMÉ	327	3.4%
ABATTU	**44**	**0.5%**
REMPLACÉ	26	0.3%
Essouché	11	0.1%

Constat n°1 : Les arbres `ABATTU` ne représentent que **0.5%** du total, soit seulement **44 arbres** sur plus de 9 500.

Constat n°2 : La très faible proportion d'arbres abattus rend impossible l'entraînement d'un modèle de classification supervisée classique (comme Random Forest), car un modèle naïf qui prédirait systématiquement "EN PLACE" obtiendrait 99.5% de bonnes réponses sans rien apprendre.

2.2 Sélection des variables pertinentes

Sur la base de l'expertise arboricole, cinq caractéristiques ont été identifiées comme influençant la vulnérabilité d'un arbre au vent :

Variable	Rôle dans le risque
Hauteur totale	Plus l'arbre est grand, plus il prend le vent
Diamètre du tronc	Résistance mécanique (plus fin = plus vulnérable)
Situation	Isolé = pas de protection par les arbres voisins
Feuillage	Conifères = prise au vent permanente
Âge estimé	Arbres âgés = potentiellement plus fragiles

3. Construction du score de risque

3.1 Choix méthodologique

Face à l'impossibilité d'entraîner un modèle prédictif fiable, nous avons opté pour une **approche par score de risque** plutôt que par prédiction binaire.

Avantages de cette approche :

- Transparente : les règles sont compréhensibles par tous
- Amendable : les seuils peuvent être ajustés selon le retour terrain
- Actionnable : produit des niveaux de priorité opérationnels

3.2 Définition des règles

Chaque arbre se voit attribuer un score de 0 à 5 basé sur le cumul des facteurs suivants :

Règle	Condition	Point(s)
1. Hauteur importante	≥ 14 mètres	+1
2. Diamètre faible	≤ 60 centimètres	+1
3. Situation isolée	"Isolé"	+1
4. Feuillage conifère	"Conifère"	+1
5. Âge avancé	≥ 45 ans	+1

Justification des seuils : Les valeurs (14m, 60cm, 45 ans) correspondent aux 25% des arbres les plus grands, les plus fins et les plus âgés de la base de données. Cette approche garantit que les seuils sont adaptés au patrimoine local.

3.3 Niveaux de priorité opérationnelle

Niveau	Score	Action recommandée
🔴 PRIORITÉ 1	≥ 3	Inspection urgente, coupe préventive envisageable
🟠 PRIORITÉ 2	2	Inspection avant chaque épisode venteux
🟡 PRIORITÉ 3	1	Surveillance régulière, inspection annuelle
🟢 PRIORITÉ 4	0	Inspection de routine uniquement

4. Évaluation sur données historiques

4.1 Distribution du score dans la population

Score	Effectif	Pourcentage	Niveau associé
0	1 861	21.3%	🟢 PRIORITÉ 4
1	4 567	52.3%	🟡 PRIORITÉ 3
2	2 012	23.0%	🟠 PRIORITÉ 2
3	278	3.2%	🔴 PRIORITÉ 1
4	20	0.2%	🔴 PRIORITÉ 1
5	0	0.0%	🔴 PRIORITÉ 1

Constat n°3 : Seuls **3.4%** des arbres (environ 300) sont classés en priorité 1, ce qui représente une charge opérationnelle tout à fait acceptable.

4.2 Performance sur les arbres ABATTU historiques

L'évaluation a consisté à comparer le score attribué par nos règles avec le statut réel des 44 arbres ABATTU :

Seuil d'alerte	Arbres à risque détectés	Taux de détection	Arbres à surveiller
Score ≥ 1	33/44	75%	~6 800
Score ≥ 2	6/44	**14%**	~2 300
Score ≥ 3	0/44	0%	~300

Constat n°4 (important) : Les arbres effectivement abattus ont un score de risque **plus faible** que la moyenne des arbres en place (score moyen de 0.89 contre 1.09).

Interprétation : Cette contre-performance s'explique par le fait que les 44 arbres ABATTU ne sont pas représentatifs des chablis liés aux tempêtes. Ils incluent probablement des arbres abattus pour d'autres raisons (maladie, travaux, sécurité préventive).

4.3 Profil des arbres ABATTU non détectés

L'analyse des 38 arbres ABATTU non détectés (score < 2) révèle le profil suivant :

Caractéristique	Valeur moyenne	Comparaison population
Hauteur	9.5 m	Plus petits (-1.4 m)
Diamètre	92 cm	Plus fins (-8 cm)
Âge	33 ans	Similaire
Proportion d'isolés	13%	Légèrement inférieure
Proportion de conifères	26%	Légèrement supérieure

Constat n°5 : Les arbres abattus ne correspondent pas au profil "grand, isolé, conifère" que l'expertise arboricole associe classiquement aux chablis. Ce résultat confirme que les abattages dans cette base sont majoritairement dus à d'autres causes.

---

5. Bilan des performances

5.1 Synthèse des résultats

Métrique	Valeur	Appréciation
Arbres analysés	9 551	Périmètre complet
Arbres ABATTU disponibles	44	Échantillon très limité
Score maximum observé	4/5	Aucun arbre ne cumule les 5 facteurs
Gain opérationnel	-97%	300 arbres prioritaires au lieu de 9 500

5.2 Compromis détection / charge opérationnelle

Option	Détection	Charge travail	Recommandation
Seuil ≥ 1	75%	Très lourde (~6 800 arbres)	Non retenue
Seuil ≥ 2	14%	Moyenne (~2 300 arbres)	À tester sur le terrain
Seuil ≥ 3	0%	Faible (~300 arbres)	Non retenue

Recommandation : Tester le seuil ≥ 2 sur une zone pilote pour évaluer la pertinence réelles des alertes générées.

---

6. Préconisations pour la ville

6.1 Utilisation opérationnelle

Phase	Action
Avant la saison des tempêtes	Exécuter le script sur l'ensemble du patrimoine pour identifier les arbres prioritaires
Avant chaque alerte météo	Inspecter les arbres de priorité 1 (score ≥ 3) et 2 (score = 2)
Après la tempête	Enregistrer les nouveaux chablis et enrichir la base

6.2 Axes d'amélioration

1. **Enrichissement des données**
    - Documenter systématiquement la cause précise de chaque abattage
    - Distinguer "abattu suite à tempête" des autres causes
    - Ajouter l'état sanitaire des arbres (absent dans la base actuelle)
2. **Calibration terrain**

    - Tester les seuils sur une zone pilote
    - Ajuster les règles selon le retour terrain
    - Collecter au moins 200-300 exemples de chablis pour une éventuelle modélisation future

3. **Intégration SIG**
    - Cartographier les arbres par niveau de priorité
    - Planifier les tournées d'inspection par zone

6.3 Limites à communiquer

Limite	Impact	Mesure d'atténuation
Faible nombre d'ABATTU (44)	Performance non représentative	À réévaluer après collecte de données
Causes d'abattage non documentées	Biais dans l'évaluation	Distinguer les causes à l'avenir
Absence de données sanitaires	Facteur de risque manquant	Ajouter cette information

---

7. Conclusion

7.1 Réponse au besoin client

Malgré les contraintes du jeu de données (déséquilibre extrême, faible volume d'ABATTU, causes non documentées), nous avons développé un **outil de priorisation opérationnel** basé sur :

- Des règles métier transparentes et amendables
- Un score de risque à 4 niveaux d'alerte
- Une réduction de la charge d'inspection de **97%**

7.2 Positionnement du livrable

Notre livrable est une **aide à la décision**, pas une vérité absolue. Il permet aux services municipaux de :

1. **Concentrer leurs efforts** sur les arbres les plus vulnérables
2. **Objectiver** leurs décisions d'inspection
3. **Améliorer** le système au fil de l'eau par l'expérience terrain

---

8. Annexes

8.1 Arbres prioritaires par quartier

Les données détaillées par quartier sont disponibles dans le fichier `arbres_prioritaires.csv` livré avec le projet.

8.2 Seuils utilisés

Seuil	Valeur	Justification
Hauteur	≥ 14 m	75ème percentile
Diamètre	≤ 60 cm	25ème percentile
Âge	≥ 45 ans	75ème percentile

8.3 Glossaire

Terme	Définition
Chablis	Arbre déraciné ou brisé par le vent
Conifère	Arbre à feuillage persistant (pin, sapin, épicéa)
Feuillu	Arbre à feuillage caduc (chêne, érable, tilleul)
Faux négatif	Arbre dangereux non détecté par l'alerte
Faux positif	Arbre sain déclenchant une alerte

Rédigé par : Allan Steed MIHINDOU
Date : 24-04-2026
Projet : ISEN CIPA4 - Projet Big Data / IA / Web